abyss

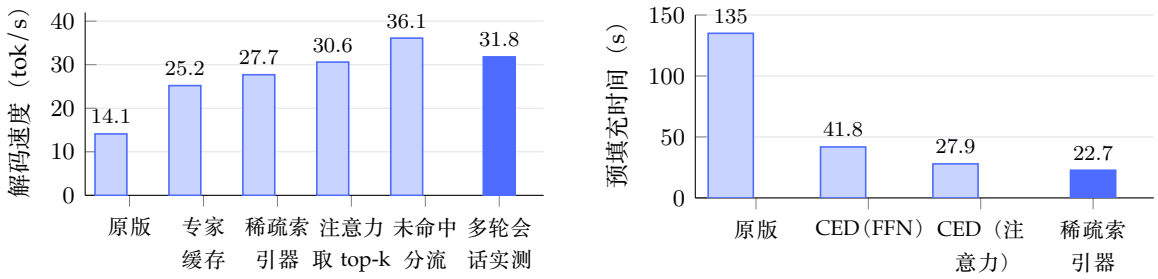
Abyss：在两张显卡上分层运行 DeepSeek-V4.1-Flash

Abyss

2026 年 10 月

摘要

长上下文智能体把推理的压力从算力推到了显存、内存和 PCIe 上。DeepSeek-V4.1-Flash 总参数 763B，原生权重约 474 GiB，超过一台双卡工作站（2 × RTX PRO 6000 Max-Q，显存合计 191 GiB；内存 192 GB）的全部容量。我们在 mx-llama.cpp 上实现了一个分层推理调度器 Abyss：编码器各层的专家常驻显存，解码器后 18 层的专家放在主机内存，由 GPU 上的专家缓存和 CPU 分担，Engram 大表留在 NVMe。围绕这款模型的编码器-解码器结构（CED）、压缩注意力和稀疏索引器，我们依次实现了 CED 感知预填充、Engram 预取、官方稀疏索引器、解码注意力的 top-k 收集、按热度准入的专家缓存未命中分流、预填充大批次的 CPU 分流，以及让提示词末段一遍算完的调用合并，最后把内存从 3600 MT/s 提到 5200 MT/s。在保持原生 MXFP4 精度的前提下（每项改动对改动前的 KLD 都在数值底线以内），预填充的提升最大：4.8 万 token 提示词从 135 s（355 tok/s）降到 22.7 s（2,111 tok/s），快约 6 倍，其中 CED 感知预填充把解码器层的计算量从约 96 万个「token × 层」降到约 2.4 万个，贡献最大；Engram 页缓存冷时，预取把冷读开销从约 39 s 降到约 2 s；多轮智能体会话里，之后每轮（1,200–1,600 token）的预填充从 5.7–7.2 s 降到 2.7–3.2 s。解码从 4.8 万上下文的 14.1 tok/s 提升到只追加的多轮会话里的 31–33 tok/s，4.8 万和 9.6 万上下文一样；剩下的时间主要花在把未命中的专家从内存经 PCIe 搬到 GPU。最后把上下文从 12.8 万扩到 19.2 万：专家缓存从 14 GB 减到 12 GB，预填充不变，解码慢约 3%。我们同时记录了评估方法（两档数值底线、对官方实现的单层对拍、逐 token 剖析）、一个让解码速度虚高的测法陷阱，以及在真实 Codex 负载中发现并修复的缺陷。



(a) (b)

图 1 | (a) 4.8 万上下文的单流解码速度，依次叠加各项优化（第 4 节）；第 3–5 根是同一提示词第二次生成，缓存命中偏高；最后一根是只追加的多轮会话实测（9.6 万上下文、内存 5200 MT/s，§4.4）。(b) 4.8 万 token 提示词的预填充时间，Engram 页缓存已热（第 5 节）。

目录

1 引言 4

2 硬件与模型 4

2.1 硬件 4
2.2 模型 5
2.3 权重格式与量化 6
2.4 方案 B 的布局 8

3 评估方法 8

3.1 数值底线 8
3.2 对官方实现的对拍 10
3.3 剖析 10

4 解码 10

4.1 GPU 专家缓存 10
4.2 解码注意力只取 top-k 行 11
4.3 按热度准入的未命中分流 11
4.4 实际会话中的解码速度 12

5 预填充 13

5.1 CED 感知预填充 13
5.2 Engram 预取 14
5.3 补上官方稀疏索引器 14
5.4 大批次分流 14
5.5 末段一遍算完 16

6 服务与智能体负载 16

6.1 多轮会话的缓存复用 16

6.2 prompt 缓存的选择 17
6.3 真实负载暴露的缺陷 17
6.4 重启后的长对话首次预填充 17

7 把内存提到 5200 MT/s **18**

8 把上下文扩到 19.2 万 **18**

9 结论、局限与未来方向 **20**

A 补丁清单 **22**

B 复现 **22**

C 术语表 **23**

1 引言

智能体把大模型的典型请求从「短问短答」变成了「长上下文、多轮、带工具调用」。一个编程智能体每一轮都要在几万 token 的上下文后面追加回复、工具结果或追问，再让模型继续生成。这种负载有两个特点：一是上下文长，注意力和 KV 的开销随之增长；二是每一轮新增的内容不多，但首 token 之前的那段预填充决定了用户等待的时间。

DeepSeek-V4.1-Flash [1] 是为这类负载设计的。它有 552B 主干参数、196.6B 的 Engram 查表和约 14B 的 DSpark 草稿模型；40 层中前 20 层是因果编码器、后 20 层是解码器（CED），提示词的每个 token 只需走完编码器，生成的 token 才走完全部 40 层；注意力把 KV 按 2 倍或 1 倍压缩，再由稀疏索引器为每个查询挑出 512 个压缩位置；路由专家 384 个，每个 token 选 6 个，权重是原生 MXFP4。

问题在于容量。原生权重约 474 GiB（专家 268.9 GiB，Engram 189 GiB），而我们的机器只有两张 RTX PRO 6000 Max-Q（每张 95.6 GiB）和 192 GB 内存，合计约 383 GiB。公开的双卡方案 [3] 把专家量化到 3.0 bpw，速度很快（同样两张 RTX PRO 6000，单流解码 66–74 tok/s，4.6 万 token 提示词预填充约 1 万 tok/s），但相对原版的 KL 散度为 0.0545、top-1 一致率 92.9%，而且需要约 250 GiB 空闲内存，本机放不下。我们选择了另一条路：保留原生 MXFP4，把权重按热度分布在显存、内存和 NVMe 三层（方案 B），在 mx-llama.cpp [2] 上实现调度器 Abyss，再逐项找出瓶颈并优化。

本报告记录这一过程。主要结果见表 1：

- **解码**：GPU 专家缓存、解码注意力只取 top-k 行、按热度准入的未命中分流，使解码从 14.1 tok/s 提升到只追加的多轮会话里约 30 tok/s（内存 3600 MT/s），4.8 万和 9.6 万上下文一样；内存提到 5200 MT/s 后为 31–33 tok/s。
- **预填充**：CED 感知预填充让解码器层只计算后面还能看到的 token，加上 Engram 预取和官方稀疏索引器，4.8 万 token 提示词从 135 s 降到 22.7 s；大批次分流和末段一遍算完再把多轮会话每轮的预填充从 5.7–7.2 s 降到 2.9–3.5 s。
- **测法**：同一提示词第二次、一字不差的生成会让专家缓存命中偏高，解码速度虚高约 15–20%。我们用只追加的多轮会话重新测量，并据此修正了此前的结论。
- **正确性**：所有改动都有对拍。我们区分了两档数值底线，并对稀疏索引器和解码注意力做了对官方 PyTorch 实现、对 float64 的逐层对拍。
- **真实负载**：在 Codex 的实际请求中发现了 prompt 缓存的选择问题和三处只在特定提示词长度下出现的崩溃，均已修复。

2 硬件与模型

2.1 硬件

表 2 是机器的配置和实测带宽。两点决定了后面的设计：内存是双通道、每通道两条，优化过程中运行在 3600 MT/s，纯读只有约 44 GB/s（最后提到 5200 MT/s，见第 7 节）；两张卡各

表 1 | 各阶段的改动与效果。解码在 4.8 万上下文下测；预填充为 4.8 万 token 提示词、Engram 页缓存已热；KLD 是对改动前的 logits，「—」表示没有改变数值。

补丁	改动	效果	对拍
环境变量	预填充的 MXFP4 矩阵乘改用 8 bit 激活（W4A8）	预填充约慢 5%	0.044 → 0.012*
分支自带	GPU1 上的专家缓存（14 GB，约 780 槽位，LRU）	解码 14.1 → 25.2 tok/s	0.0005
0003	CED 感知预填充：解码器层只算可见 token 的 FFN	预填充 135 → 41.8 s	0.00004
0004	Engram 整批预取	冷缓存 91.1 → 54.3 s	—
0005	解码器层的注意力也只算子集	41.8 → 27.9 s	0.00007
0006	补上官方稀疏索引器（top-512）	27.9 → 22.7 s；修正长上下文	见 §5.3
0008	解码注意力只取 top-k 行	解码 27.7 → 30.6 tok/s‡	0.003†
0009	未命中按热度一半上传、一半交给 CPU	30.6 → 36.1 tok/s‡	0.0003†
0014	预填充大批次分流	每轮 5.7–7.2 → 4.6–5.6 s	0.0005
0015	提示词末段一遍算完：末段不拆调用，最后一个 ubatch 对齐到满	每轮 4.6–5.6 → 2.9–3.5 s	0.009§
BIOS	内存 3600 → 5200 MT/s	解码约 +6%，每轮 2.7–3.2 s	重跑一致
配置	上下文 12.8 万 → 19.2 万，专家缓存 14 → 12 GB	解码约 −3%，预填充不变	0.000005

* 预填充路径对解码路径的 KLD，不是对改动前。† server 上 temperature 0 生成时的 top-20 KL；0008 经过编码器层，属于较高的一档底线（§3.1）。‡ 同一提示词第二次、一字不差的生成，缓存命中偏高；只追加的多轮会话见 §4.4。§ 和只换 ubatch 大小的差别一样（§5.5）。

走 PCIe 5.0 x8，单卡主机到显存约 28.9 GB/s，但两卡同时从主机读合计只有 43.4 GB/s，被内存带宽卡住。所以无论专家由 CPU 计算还是上传到 GPU，每读一个专家都要占用同一份内存带宽。

2.2 模型

图 2 是 DeepSeek-V4.1-Flash 的逐层结构和方案 B 在本机的布局，维度取自 GGUF 元数据。与本报告相关的结构特点有四个：

- **编码器-解码器（CED）**。第 0–19 层是因果编码器，第 20 层的压缩器生成所有解码器层共享的全局 KV。解码器层只通过各自 128 个 token 的滑动窗口读自己的隐状态，因此提示词前面的大部分 token 不需要走完解码器。
- **压缩注意力**。第 0–1 层只有滑动窗口；第 2–19 层把每 2 个 token 压成一行，第 20–39 层每个 token 一行。压缩 KV 只在第 2、8、14、20 层写入，其后的层复用。每个查询有 64 个头，键值只有 1 个 512 维的头（K = V）。
- **稀疏索引器**。第 2、8、14、20、24、28、32、36 层用 32 个头、128 维、FP4 的查询和键给压缩位置打分，选出 top-512；第 20 层还按每 8 行一块挑出 2,048 个候选块，供第 24–36 层重选。其余层沿用最近索引源的结果。

表 2 | 硬件与实测带宽（2026-10-20，STREAM 与 nvbandwidth；括号里是 2026-10-25 内存提到 5200 MT/s 后的值）。

项目	配置与实测
GPU	2 × RTX PRO 6000 Blackwell Max-Q（300 W），每张 97,887 MiB GDDR7，SM120
互联	PCIe 5.0 x8 / x8，P2P 经 CPU，无 NVLink；卡间单向约 27.7 GB/s
CPU	AMD Ryzen 9 9950X，16 核 32 线程，单 NUMA
内存	4 × 48 GB DDR5（双 rank），双通道 2DPC，3600 MT/s；纯读 44 GB/s，STREAM Copy 42 / Triad 32 GB/s（5200 MT/s：54、53.5 / 39.7）
主机 → 显存	单卡 28.9 GB/s；两卡同时合计 43.4 GB/s（5200 MT/s：50.6）
存储	Samsung 9100 PRO 4TB（PCIe 5.0）、990 PRO 4TB（PCIe 4.0）

- **专家与 Engram**。每层 384 个路由专家选 6 个，外加 1 个共享专家；每个 MXFP4 专家约 18.8 MB，每层 7.2 GB。第 1、14 层按最近 2–4 个 token 的 n-gram 哈希查两张约 3.84 亿行的大表。

2.3 权重格式与量化

本报告的优化都没有对模型再做量化：改动的只是权重放在哪一层，以及哪些 token、哪些行不必计算，每项改动都和改动前对拍（§3.1）。不过我们运行的 GGUF [2] 本身和官方 checkpoint 不完全相同。表 3 是逐个统计 12 个分片的结果。

表 3 | GGUF 中各类权重的格式，与官方 checkpoint 对比。

权重	官方	GGUF	大小	精度变化
路由专家	FP4（E2M1，每 32 个一个缩放）	MXFP4	275.7 GiB	无，同一种格式
注意力等稠密矩阵	FP8	Q8_0	5.5 GiB	很小，都是 8 bit，只是缩放方式不同
共享专家	FP8*	Q8_0	1.5 GiB	同上
Engram 表	**FP8，约 189 GiB**	**MXFP4**	**97.3 GiB**	**从 8 bit 降到 4 bit**
嵌入、输出、路由门、压缩器、索引器投影	—	BF16	2.8 GiB	无
各种 norm、偏置	—	F32	0.2 GiB	无

* 按官方 `inference/model.py` 推断：只有路由专家用 FP4，其余线性层走 FP8 矩阵乘；共享专家没有单独核对。
—：未单独核对，GGUF 中是 16 位或 32 位浮点。

真正降了精度的只有 Engram 表。转换 GGUF 时它从 FP8 压到了 MXFP4，体积减半，也更容易留在页缓存里。这是转换者的选择，我们直接继承；本报告的对拍都是同一个 GGUF 改动前后的比较，这一步对质量的影响没有测过，要测需要用官方 FP8 的表做参照。

计算时还有两处量化。GPU 和 CPU 上的矩阵乘都先把激活按 32 个一组量化成 int8 再乘，即 W4A8；官方参考实现用 FP8 激活，同为 8 bit。fork 在 Blackwell 上的预填充默认是 W4A4

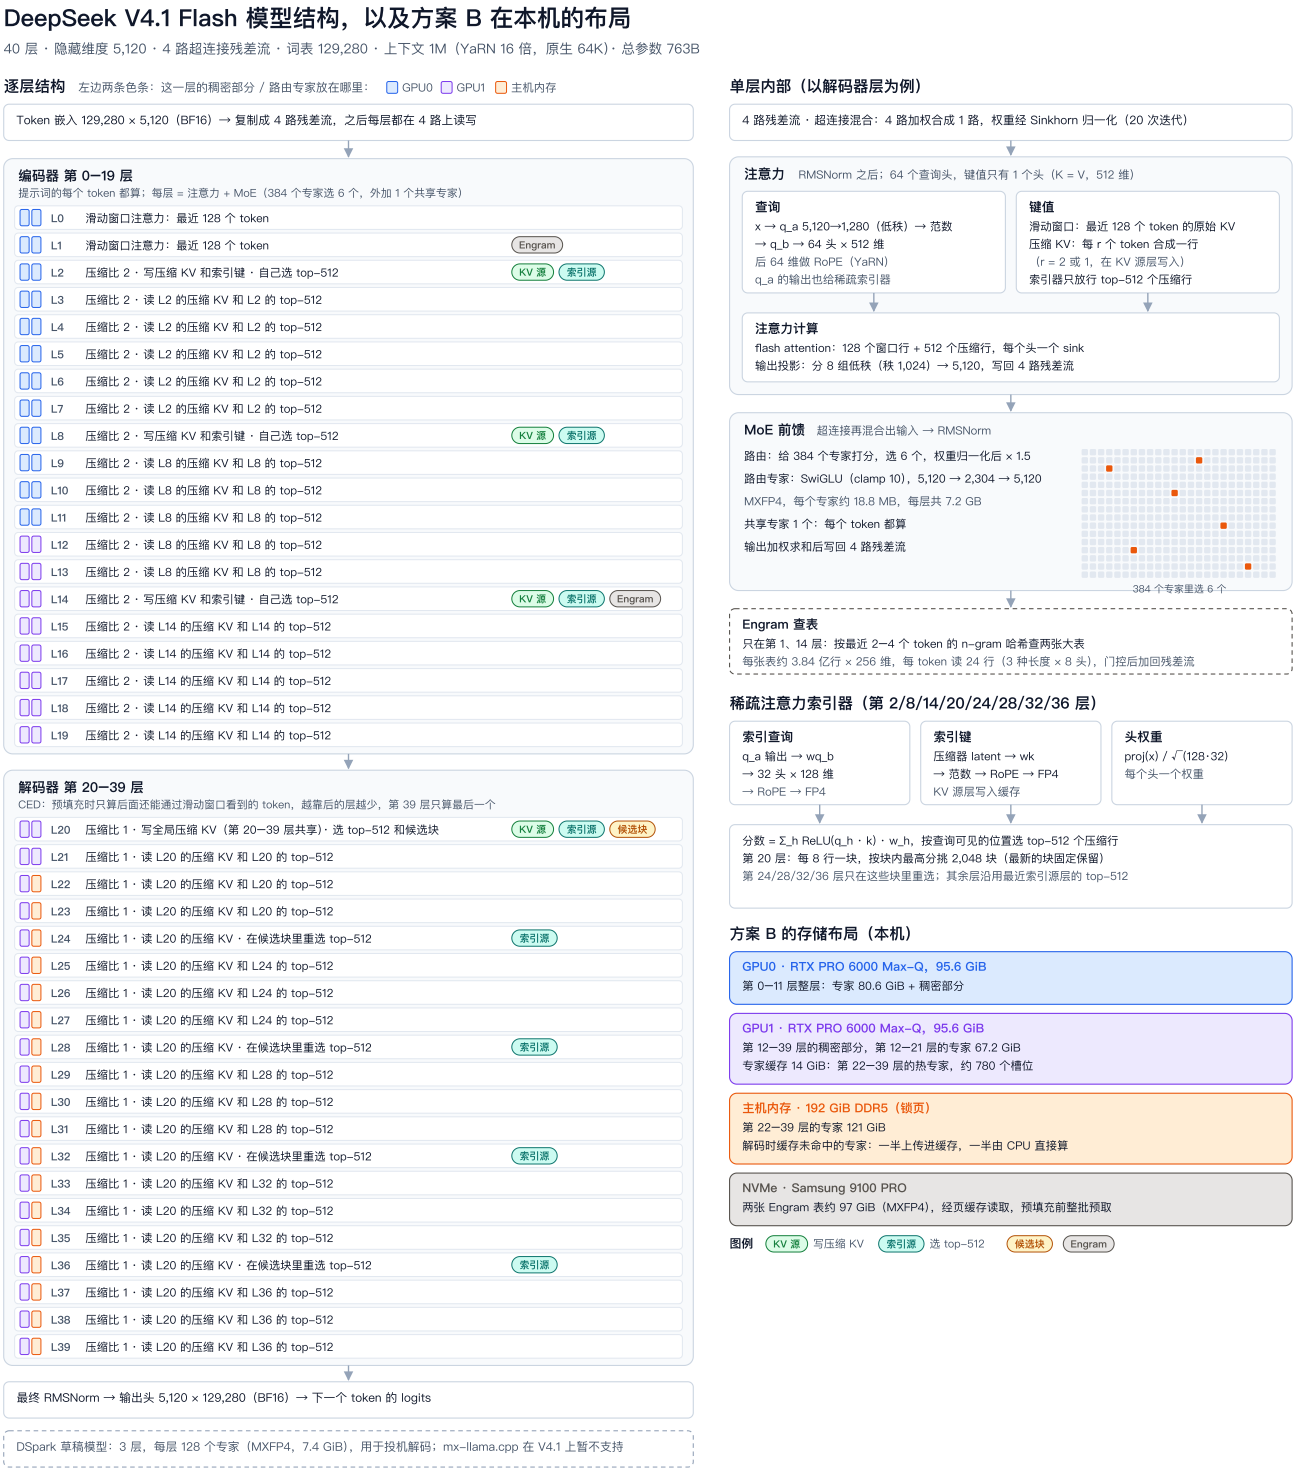


图 2 | DeepSeek-V4.1-Flash 的逐层结构，以及方案 B 在本机的布局。左侧每行一层，色条表示该层稠密部分和路由专家所在的位置；右侧是单层内部、稀疏索引器和存储布局。

（激活只有 4 bit），我们改回了 8 bit（§3.1）。稀疏索引器的查询和键用 FP4，这是官方的设计，我们照官方实现做。KV cache 用默认的 F16，没有量化。

作为对比，方案 A 要把路由专家从约 4.25 bpw 再压到 3.0 bpw，相对原版的 KL 散度为 0.0545 [3]；方案 B 不做这一步，这正是选它的原因。

2.4 方案 B 的布局

方案 B 用层切分（`-sm layer -ts 12/29`）：GPU0 放第 0–11 层整层；GPU1 放第 12–39 层的稠密部分和第 12–21 层的专家；第 22–39 层的专家（121 GiB）放在锁页主机内存；Engram 表留在 NVMe，经页缓存读取。编码器的专家全部在显存，所以只要提示词不走解码器层，预填充就基本不碰主机内存。表 4 列出各层的内容。后来加入的 GPU1 专家缓存占 14 GB，大批次分流让 GPU0 的计算缓冲区多占约 1.9 GB；12.8 万上下文时，两张卡分别只剩约 3.6 GB 和 1.2 GB。上下文扩到 19.2 万后，专家缓存降到 12 GB（§8）。

表 4 | 方案 B 的存储布局（最终配置）。

位置	内容	容量
GPU0	第 0–11 层整层（专家 80.6 GiB + 稠密部分）	95.6 GiB
GPU1	第 12–39 层稠密部分，第 12–21 层专家 67.2 GiB，专家缓存 12 GB	95.6 GiB
主机内存	第 22–39 层专家 121 GiB（CUDA_Host 锁页）	192 GB
NVMe	两张 Engram 表（MXFP4，约 97 GiB）	4 TB

图 3 把放置和运行时的分工画在一起。解码时两张卡串行：GPU0 只算前 12 层，每 token 约 4 ms；GPU1 算其余 28 层和输出层，还要等未命中的专家从内存上传，是解码的瓶颈，CPU 同时分担一半未命中的专家。预填充时编码器层的全部 token 都在显存里算，解码器层只算提示词末尾还用得到的 token；第 22–39 层的大批次专家沿用 fork 的做法上传到 GPU0 计算，分到 token 少的专家由 CPU 同时算（§5.4）。

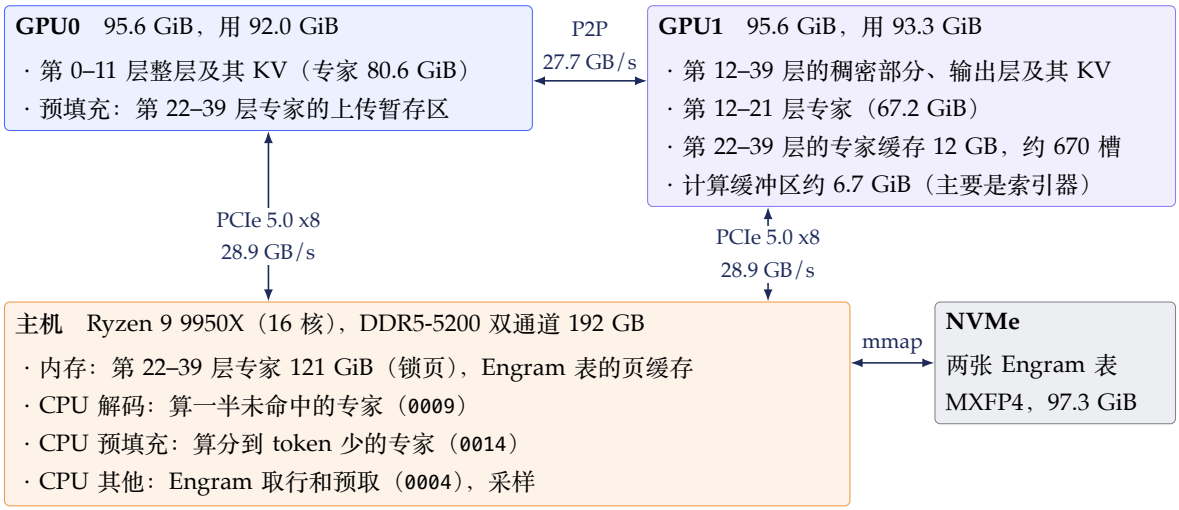
3 评估方法

3.1 数值底线

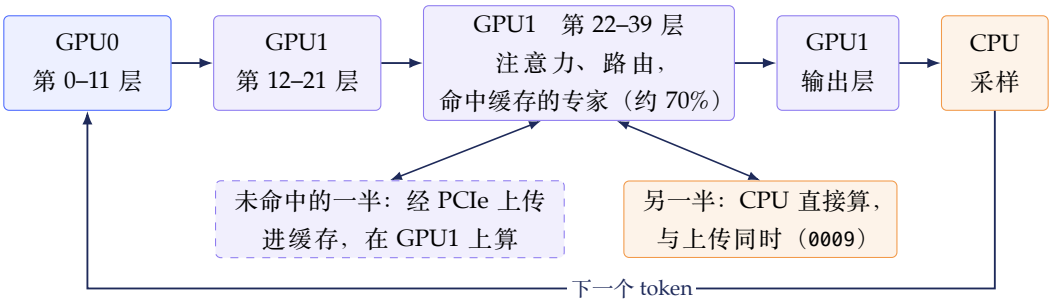
我们用 llama.cpp 的 KL 散度对拍：先存一份基准 logits，再比较改动后的 logits。早期的编译同一配置重跑完全相同（KLD 为 0）；加了后来的补丁后，重跑之间 KLD 平均约 0、最大约 6e-5，top-1 一致率 100%。重要的发现是数值底线分两档（表 5）：

- 改动只落在解码器层（第 20–39 层）时，KLD 约 0.0005。例如把第 22–39 层的专家从 CPU 改到 GPU 上计算。
- 改动经过编码器层（第 0–19 层）时，0.005–0.01 属正常。例如只把第 5 层的专家改到 CPU 计算就是 0.0064；换内核、关融合、换 ubatch 也在这个量级。

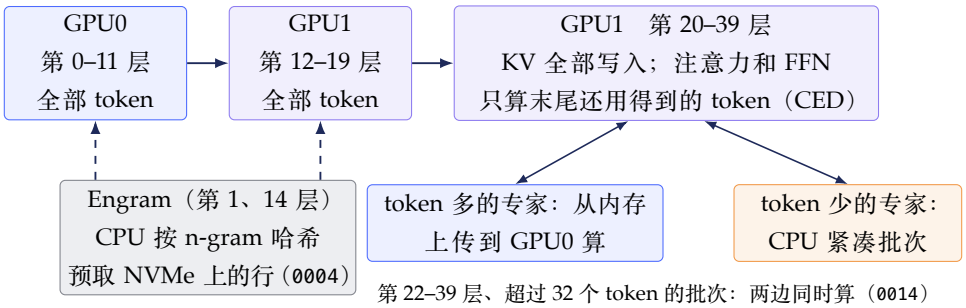
原因在 CED：编码器的输出决定了所有位置共享的全局 KV，那里的舍入差别会扩散到之



(a) 放置与链路（19.2 万上下文的配置，§8）



(b) 解码一个 token：两张卡串行



(c) 一次预填充调用

图 3 | 方案 B 中 GPU0、GPU1 和主机的分工。蓝色是 GPU0，紫色是 GPU1，橙色是 CPU 和内存，灰色是 NVMe；两卡之间没有 NVLink，P2P 经 CPU 转发。(b) 中两张卡串行，9.6 万上下文时每 token 约 37 ms：上传未命中专家 14.5 ms、GPU1 内核 10.5 ms、GPU0 内核 4.2 ms、两卡都空闲 7.9 ms（表 7）。(c) 中编码器层算全部 token，解码器层只算末尾子集（§5.1）。

后所有位置；解码器层的差别只影响当前 token。判断一项改动是否正确，必须先确定它落在哪一档。

同一套方法一开始就查出了一个精度问题：mx-llama.cpp 在 Blackwell 上对 MXFP4 的预填充默认用 W4A4（激活量化到 4 bit），而官方参考实现是 W4A8。预填充路径对解码路径的 KLD 因此高达 0.044、top-1 一致率 91%；改为 8 bit 激活后降到 0.012、95%，与数值底线相当，预填充只慢约 5%。

表 5 | 数值底线与 W4A4 问题（2026-10-21）。

比较	改动范围	KLD
同一配置重跑	—	0（后来最大 6e-5）
第 22–39 层专家从 CPU 改到 GPU	只有解码器层	0.0005
第 5 层专家从 GPU 改到 CPU	经过编码器层	0.0064
预填充 W4A4 对解码路径	全部层	0.044
预填充 W4A8 对解码路径	全部层	0.012

3.2 对官方实现的对拍

KLD 只能说明最终输出变了多少，不能说明是哪一步造成的。对实现复杂的部分，我们写了独立的参照实现（oracle）逐层对拍：用 `llama-abyss-dump` 导出 fork 计算图里指定的张量，再用 PyTorch 按官方 `inference/model.py` 从同样的输入重算。解码步的注意力还用 float64 重算，单独量出内核的舍入误差。具体结果见 §5.3 和 §4.2。

3.3 剖析

性能问题一律先剖析再动手。我们用 nsys 抓取一段预填充或一段解码，按设备统计内核、拷贝和空闲时间，再按 token 平均（`tools/eval/nsys_breakdown.py`、`nsys_decode.py`）。多轮智能体用一个模拟 Codex 的脚本测量：首轮带 4.8 万 token 的文档和两个工具，之后每轮回填约 1,500 token 的工具结果或追问，逐轮记录缓存复用和预填充时间（`agent-turns.sh`）。

4 解码

方案 B 的原版解码是 16.5 tok/s（空上下文），4 万上下文时约 14.6 tok/s。瓶颈是 CPU：解码器后 18 层每个 token 要读 108 个专家、约 2.0 GB，而内存带宽只有 44 GB/s。

4.1 GPU 专家缓存

mx-llama.cpp 自带一个实验性的专家缓存：在 GPU1 上划出一组槽位（bank），每层一张「专家号 → 槽位号」的映射，命中的专家直接在 GPU 上算，未命中的同步上传并按 LRU 淘汰。我们给它 14 GB（约 780 个槽位，占第 22–39 层专家的 11%）。真实文本的专家局部性很强，LRU 命中率约 75%；4.8 万上下文的解码从 14.1 提升到 25.2 tok/s，短上下文约 29–30 tok/s，KLD 0.0005。

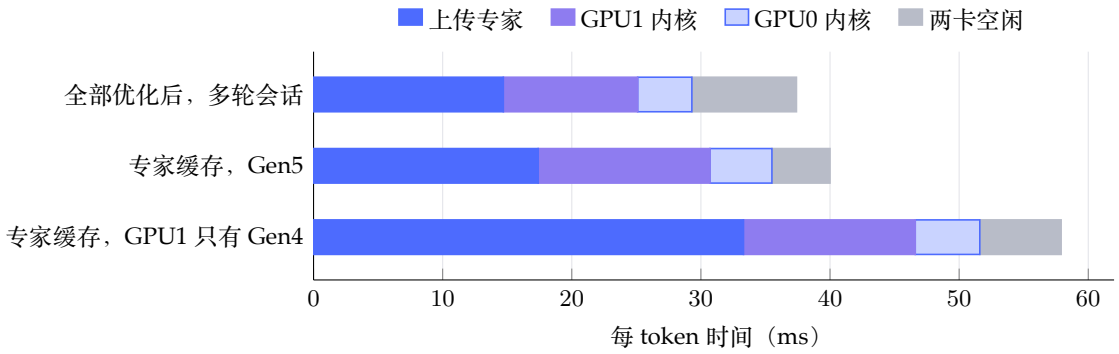


图 4 | 4.8 万上下文解码的每 token 时间（nsys，内存 3600 MT/s）。中间一行是只开专家缓存时；下面一行是一次开机后 GPU1 的链路只训练到 Gen4 时，上传慢了一倍（§6.3）；上面一行是全部优化后、只追加的多轮会话中，每 token 37.5 ms（§4.4）。

开启缓存后，我们在 PCIe Gen5 下剖析了 4.8 万上下文的解码（图 4）：每 token 40.1 ms，其中 GPU1 上传未命中专家 17.4 ms（约 26.5 个、474 MiB），GPU1 内核 13.3 ms，GPU0 内核 4.8 ms，两卡都空闲 4.5 ms，几部分基本串行。上传是最大的一块。

4.2 解码注意力只取 top-k 行

剖析还显示 GPU1 内核里有约 3 ms 花在 `concat_cont` 上，而且随上下文增长：每层每个 token 都把滑动窗口和整个压缩 KV 拼成一个张量（4.8 万上下文时每次约 40 μs），再由 flash attention 按 top-512 掩码挑行。单个查询时这是浪费的：它只会看到 512 个压缩行。我们改为先用 `get_rows` 取出这 512 行和它们的掩码，再和滑动窗口拼接，补齐到 256 的倍数后走普通 flash attention。

4.8 万上下文的解码从 27.7 提升到 30.6 tok/s，12.8 万上下文从 23.9 提升到 30.9 tok/s（都是同一提示词第二次生成，§4.4），解码速度基本不再随上下文变长而下降。server 上 temperature 0 生成的 top-20 KL 约 0.003，高于解码器层那一档底线。我们用 float64 对拍确认了原因：给定相同输入时，两条路径看到的是同一组 640 行，和 float64 的误差都约 5e-4（F16 舍入）；第 20 层的差别来自上游——第 2–19 层约 5e-4 的舍入差别经 MoE 在分数接近的专家之间选择而被放大，这正是「经过编码器层」那一档的机制。

4.3 按热度准入的未命中分流

原设计是把未命中全部交给 CPU 计算，只按静态热表换入。剖析后发现这行不通：LRU 的高命中率靠的是每个未命中都换入，不换入时命中率会掉到静态热表的水平（每 token 约 47 次未命中），CPU 计算反而比上传还慢；CPU 算完再把同一个专家上传，又要从内存读两遍。

我们改为按热度准入。每层由一个 CPU 算子规划：命中的照常读缓存；未命中的按衰减热度（每层每步乘 0.99）挑出一定比例，立即异步上传进 LRU 槽位；其余由 CPU 用主机内存里的原始专家计算，GPU 那边读 bank 末尾的全零槽位，down 之后两边相加。计算图里 CPU 分支先于 GPU 分支展开，规划算子在 CPU split 开头发出上传，CPU 计算其余未命中时 DMA 正在进行，每个专家只从内存读一遍。

表 6 是上传比例的扫描。只上传一半，命中率不降：按热度挑出来的才进缓存，冷门专家不会把缓存冲掉。最终取 0.5：4.8 万上下文 36.1 tok/s，12.8 万上下文 36.2 tok/s，KL 约 2e-4，低于解码器层底线。这两个数和表里的速度一样，都是同一提示词第二次生成测出的，偏高；实际会话见下节。

表 6 | 未命中上传比例的扫描（4.8 万上下文，已开启 top-k 收集，复用提示词缓存后生成 256 token，即同一提示词第二次、一字不差的生成）。

上传比例	解码（tok/s）	命中率	对全部上传的 top-20 KL
全部上传（原缓存）	30.6	75.5%	—
1.0（新路径）	30.2	75.5%	0（逐位一致）
0.5	36.1	75.9%	2.7e-4
0.4	35.7	75.1%	2.2e-4
0.3	36.4	74.5%	1.7e-4
0.2	36.0	73.1%	2.2e-4
0（全部交给 CPU）	16.1	0%	1.8e-4

4.4 实际会话中的解码速度

Codex 的实际会话（上下文约 10 万 token）解码只有 30–31 tok/s，明显低于表 6 的 36。差别在测法：表里的速度来自同一提示词的第二次生成，temperature 0 下它和第一次一字不差，第一次用过的专家正好还在 LRU 缓存里，命中率偏高；同一脚本里第一次生成只有 32–35 tok/s。Codex 自带的测速在短上下文下得到 47–49 tok/s，也是同一段生成重复跑出来的。

我们改用只追加的会话测量（`decode_modes.sh`）：首轮放文档和工具定义，之后每轮追加上一轮的回答和一个新问题，生成 256 个 token，轮换贪心或默认采样、流式或不流式。9.6 万上下文 27–31 tok/s，4.8 万上下文 27–29 tok/s，四种方式没有差别，和 Codex 的实际会话一致。所以解码既不受流式和采样影响，上下文从 4.8 万到 9.6 万也不变慢。

表 7 | 只追加的多轮会话中每 token 的时间（nsys，内存 3600 MT/s）。

部分	9.6 万上下文	4.8 万上下文
GPU1 上传未命中专家（约 20 个、360 MiB）	14.5 ms	14.7 ms
GPU1 内核	10.5 ms	10.4 ms
GPU0 内核	4.2 ms	4.2 ms
两卡都空闲	7.9 ms	8.1 ms
合计（nsys 下）	37.1 ms	37.5 ms

表 7 是剖析结果。和上下文长度有关的内核（注意力、索引器打分、top-k、取行和拼接）在 9.6 万上下文时合计只有约 2 ms，top-k 已经是基数选择。一个解码器层的时间线是：GPU1 先算上一层专家的合并、本层注意力和路由（127 个内核，约 0.47 ms）；路由结果和本层输入传回主机后，上传 1 个未命中的专家（3 × 6.3 MB，约 0.70 ms），同时 CPU 算另一个（约 0.79 ms）；之后 CPU 结果传回、启动下一段计算图（约 0.09 ms）。上传和 CPU 计算同时从

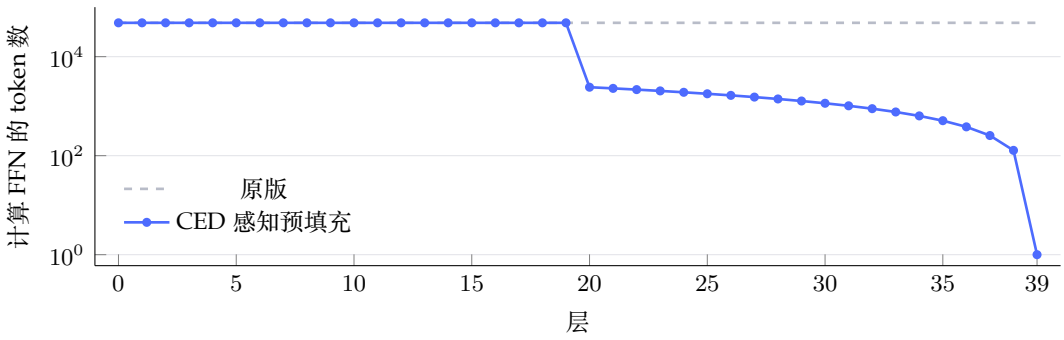


图 5 | 4.8 万 token 提示词每层计算 FFN 的 token 数（按实现中的规划规则计算，没开 DSpark 时不留余量）。编码器层全部计算；解码器层只计算后面还能通过滑动窗口看到的 token。

内存读约 37.6 MB，用了约 0.8 ms，已经到内存带宽的上限；而 GPU 上能挪到上传期间去算的只有本层命中的专家，每层不到 0.1 ms。所以解码剩下的时间主要是每层串行的未命中处理，把上传和命中专家的计算并行起来，每 token 最多省 2–3 ms。

内存提到 5200 MT/s 后（第 7 节），Codex 又用每次不同的短提示词测了一次：生成 128 或 256 个 token，9 次的中位数是 40.3 tok/s（36.8–44.8）。同一时段 Codex 自己的会话（上下文约 10.4 万）是 32.4 tok/s，和表 11 的 31–33 一致。短上下文更快，一部分是注意力相关的开销更少（9.6 万上下文时约 2 ms/token），一部分是生成内容不同、专家缓存命中率不同；到 4.8 万以上，解码就基本不再随上下文变慢。

5 预填充

原版对提示词也跑完 40 层：每个 2,048 token 的 ubatch 都要把主机内存里 121 GiB 的解码器专家读一遍。4.8 万 token 的提示词因此要 135 s（约 355 tok/s）。

5.1 CED 感知预填充

官方参考实现对提示词也跑满 40 层，CED 体现在 KV 的共享方式上：解码器层只有滑动窗口用到各层自己的隐状态。因此可以精确地裁剪：第 0–19 层全部 token 都算；第 39 层只算最后一个 token；第 L 层（20–38）只需算最后 $128 + 127 \times (38 - L)$ 个 token——每往前一层，滑动窗口让依赖往前延伸 127 个 token。实现原本在末尾多留 256 个位置，给投机解码的回退用；没开 DSpark 时 DSV4 不能部分回退，后来改为默认不留（§5.5）。这样解码器层合计约 2.4 万个「token × 层」，与提示词长度无关；4.8 万 token 的提示词在原版中是 $20 \times 48{,}240 \approx 96$ 万个（图 5）。

实现分两步。第一步（`0003`）只跳过 FFN，注意力仍对所有 token 计算，KV 写入完全不变；被跳过的 token 之后各层的隐状态不正确，但只会进入没有后续 token 读取的滑动窗口。每次 `llama_decode` 按自己的末尾规划，所以 server 用 `-b 65536` 让整段提示词进一次调用。4.8 万 token 的预填充从 135 s 降到 41.8 s，8k/16k 上下文对拍 KLD 0.00006 / 0.00004，top-1 一致率 99.8%。

第二步（`0005`）先剖析：此时 41.8 s 里第 20–39 层的注意力占 19.9 s。我们让这些层仍为所

有 token 写 KV，但只对 CED 子集取出查询和掩码行计算注意力。预填充降到 27.9 s（1,715 tok/s），KLD 0.00004–0.00007，temperature 0 的输出和第一步一字不差。

5.2 Engram 预取

Engram 表以 mmap 映射且设了随机访问提示，每次缺页都同步读一个 4 KiB 页，2,048 个 token 约需 2.4 s，瓶颈在缺页延迟而不在 SSD 带宽。由于行号只取决于输入 token，我们在 `llama_decode` 拿到整批后立即算出全部行号，由 8 个后台线程按地址排序后用 `MADV_WILLNEED` 预读。页缓存冷时，4.8 万 token 的预填充从 91.1 s 降到 54.3 s，冷读开销从约 39 s 降到约 2 s；热缓存时不变，结果与不预取完全一致。冷读已基本藏在计算后面，io_uring 和按行缓存等后续步骤暂缓。

5.3 补上官方稀疏索引器

fork 原本对 V4.1 的压缩 KV 做稠密注意力。压缩行在 512 以内时与官方的 top-512 选择等价，更长时就不同了：压缩比 1 的层超过约 512 个 token、压缩比 2 的层超过约 1,024 个 token 之后。智能体的上下文几乎都在这个范围里，所以这首先是正确性问题。

我们按官方 `inference/model.py` 补上了完整的索引器：KV 源层写 FP4 索引键（每 32 个一块，缩放 $2^{\lceil \log_2(\text{amax}/6) \rceil}$），索引源层计算 $\sum_h \text{ReLU}(q_h \cdot k)\, w_h$ 并选 top-512，第 20 层挑候选块，其余层沿用最近索引源的结果；flash attention 只看选中的位置。512 token 以内与稠密版 KLD 为 0；8k/16k/32k 上下文时，稀疏版的 PPL 比稠密版低 0.9% / 3.1% / 0.23%（表 8）。由于注意力只看 640 行，4.8 万 token 的预填充也从 27.9 s 降到 22.7 s，12.8 万 token 为 51.8 s（2,464 tok/s）。

表 8 | 稀疏索引器对稠密注意力（perplexity，每档 4 段）。

上下文	PPL（稠密）	PPL（稀疏）	变化	稀疏对稠密 KLD
8k	6.023	5.972	−0.9%	0.057
16k	3.009	2.916	−3.1%	0.094
32k	1.0027	1.0004	−0.23%	0.012

为确认实现与官方一致，我们导出第 2、20、24 层的索引器输入输出，用三种算术重算 top-512 并比较重合率（表 9）：全程 float32；fork 的算术（Q8_0 矩阵乘把激活量化成 int8）；官方的算术（bf16 激活，量化成 e4m3 后做 FP8 GEMM）。fork 与自己的算术重合 99.98% 以上，说明 RoPE/YaRN、FP4、权重缩放、可见性和 top-k 每一步都对；fork 离 float32 的距离（98.7–99.2%）比官方算法自己离 float32 的距离（97.1–98.7%）还近。索引键 99.99% 以上逐位一致，不一致的都是恰好落在 FP4 中点上的单个元素。

5.4 大批次分流

多轮会话里每轮新增的 token 不多，但只要批次超过 32 个 token，第 22–39 层几乎全部 384 个专家都会被用到，调度器把这些大批次的专家矩阵乘卸载到 GPU0，每层整批上传。一轮

表 9 | top-512 集合的平均重合率（4,027 token 提示词）。

层	fork 对 int8 参照	fork 对 float32	官方算术对 float32	fork 对官方算术
2	99.99%	99.16%	98.67%	98.63%
20	99.98%	98.67%	97.14%	97.11%
24	99.98%	98.85%	97.40%	97.36%

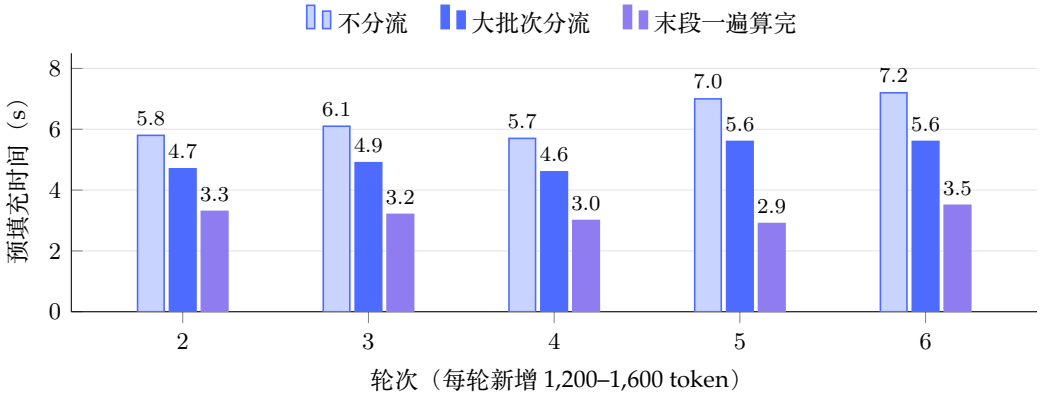


图 6 | 多轮智能体会话中每轮的预填充时间（首轮为 4.8 万 token 的文档，之后每轮回填工具结果或追问；内存 3600 MT/s）。末段一遍算完见 §5.5。

1,610 token 的预填充（7.0 s）中，GPU0 上传 145 GiB 用了 5.4 s，而 CPU、GPU1 的链路和专家缓存都闲着。这部分的下限是把这些专家从内存读一遍，约 3 s。

我们把未命中分流的思路推广到大批次：每层一个 CPU 算子统计每个专家的 token 数，按从少到多把专家交给 CPU，直到 CPU 的预计时间追上其余专家的上传时间；其余照常上传到 GPU0。为此给 CUDA 的 MMQ 补上了 id = −1 的处理（跳过并把输出清零），上传回调直接用规划算子在主机上的结果，不必从 GPU 读回 id。

第一版的 CPU 分支处理整块张量（全部 token × 6 个专家），而 CPU 实际只算约 5% 的行，量化、SwiGLU、清零和 252 MB 输出的回传把收益全吃掉了，比不分流还慢。改为紧凑批次后——只取出交给 CPU 的「token × 专家」（最多 1,024 行），在 GPU1 上取出这些 token，CPU 上按一行一个专家计算，`set_rows` 写回后与 GPU0 的结果相加——2,048 token 一批的预填充从 4.88 s 降到 4.24 s，KLD 0.00046。多轮会话之后每轮的预填充从 5.7–7.2 s 降到 4.6–5.6 s，首轮从 30.6 s 降到 27.9 s（图 6）。

这一步离下限还有约 30 ms/层：GPU0 的上传暂存区在 gate、up、down 三份权重之间复用，每段之间都要同步，CPU 要等 gate 那批传完才能开始；CPU 计算和 DMA 又共享 44 GB/s 的内存带宽。合并的几步要固定在 GPU0，否则 GPU1 的计算缓冲区会大 3.7 GB，12.8 万上下文时放不下。实现中还发现并修复了 fork 的一处问题（`0013`）：`ggml_backend_sched_reserve_size` 在切分计算图之前重置调度器，清掉了构建计算图时手动指定的后端，按错误的切分估算计算缓冲区。

5.5 末段一遍算完

CED 让每次 `llama_decode` 调用都按自己的末尾跑解码器层，凡是超过 32 个 token 的调用都要把第 22–39 层几乎全部专家从内存读一遍。server 为了建检查点，会在最后一条用户消息开头、末尾前 4 + n_ubatch 和末尾前 4 处拆调用。生产日志里 Codex 的大多数轮次因此被拆成两次大调用（例如 1,772 + 866 + 4），比同样长度只有一次调用的轮次多花 1.5–2 s；一次调用里末段跨两个 ubatch 时，也要读两遍。我们做了三处改动（`0015`）：

- 提示词最后 2,700 个 token 里不再按用户消息开头和末尾前 4 + n_ubatch 拆调用，只留末尾前 4 个 token 那次，下一轮靠它从助手前缀处接着算。会话的第一个检查点照旧，Codex 的辅助请求靠它复用系统提示。代价是这两类检查点没了：只有改写最后一条用户消息时才用得上，这时 server 退回上一轮的检查点，多算这一轮。
- 一次调用的余数放进第一个 ubatch，最后一个 ubatch 是满的 2,048 个。原来余数在最后，最后一个 ubatch 常常只有几百个 token，第 20–32 层左右都要在前一个 ubatch 里再算一遍；现在前一个 ubatch 只剩第 20–22 层的少量 token。
- 末尾的余量默认等于回退环的深度 `n_rs_seq`，没开 DSpark 时为 0。我们按规划公式逐个位置核对过，余量为 0 时下一个 token 需要的滑动窗口状态仍然完整。

表 10 | 末段一遍算完的效果（`agent-turns.sh`，内存 3600 MT/s）。

配置	首轮 4.8 万 token	之后 5 轮（1,200–1,600 token）
改动前	27.9 s	4.6–5.6 s
末段不拆调用	25.3 s	3.2–3.7 s
+ 最后一个 ubatch 对齐到满	24.4 s	3.2–3.7 s
+ 余量为 0	24.0 s	2.9–3.5 s

新提示词按外部测速的方式（关闭 prompt 缓存，每档 3 次取中位数）测，2,324 token 从 5.57 s 降到 3.69 s，4,277 token 从 8.80 s 降到 4.34 s。对拍方面，最后一个 ubatch 对齐对改动前的 KLD 是 0.0092、top-1 一致率 95.4%，和只把 ubatch 从 2048 改成 1024 的 0.0090、96.0% 一样；余量 0 对余量 256 生成的 256 个 token 全部相同（top-20 KL 4.6e-4）。我们还用 token 数组直接构造提示词，让调用长度除以 2,048 余 0、1、2、7–9、31–33、127–129、1000、2047，各测约 2 千、4 千、2 万 token，42 个请求全部正常。

6 服务与智能体负载

6.1 多轮会话的缓存复用

V4.1 的缓存不能回退到滑动窗口中间，只能退回检查点。server 在每条用户消息的开头、最后一条用户消息开头和提示词末尾附近创建检查点。模拟会话中，从第 3 轮起每轮只重算上一轮生成的回复加 4 个 token：回复经模板重新渲染后与生成时的 token 不完全一样，server 退回到「Assistant」前缀处的检查点。

6.2 prompt 缓存的选择

在 Codex 的 6 个真实请求中（预填充合计 76 s，生成 129 s），我们发现 server 只有一个槽位，Codex 的辅助请求（与主对话共享约 4,500 token 的系统提示和工具定义，只问一句）会把主对话挤出槽位。server 已把主对话存进内存里的 prompt 缓存，但主对话回来时，槽位里的辅助请求与它仍有 94% 的前缀相同，而 server 只在保留比例低于一半时才去缓存里找，并且按保留比例挑选，长的条目反而落选。

我们改为按「能直接用上的 token 数」比较槽位和缓存条目——对检查点受限的缓存，就是不晚于分叉点的最近检查点的位置——多出 256 个以上就换入；只用到一小部分的条目复制一份，原条目留在缓存里。另一个问题是辅助请求自己也从头算：系统提示末尾有检查点，但 server 要求检查点比分叉点早至少 128 个 token。这是为保存滑动窗口的检查点定的规则；V4.1 的检查点是那个位置的完整状态（`pos_min == pos_max`），在分叉点之前就能接着算。修复后，同一场景里辅助请求从 8.4 s 降到 0.3 s（只重算 13 个 token），主对话的下一轮从内存缓存换回，只重算 216 个 token、2.2 s。

6.3 真实负载暴露的缺陷

- **未分配的输入张量。**CED 让某些层在某个 ubatch 里没有 token，依赖它们的计算被整段丢掉，预先建好的输入张量就不会分配，往里写数据时断言失败。这在 CED 行映射（提示词约 2,500–16,000 token）和候选块输入（约 1.7 万 token 以上、长度除以 2,048 余约 114–622）上各出现一次，都只在特定长度下触发，测速用的 4.8 万和 12.8 万 token 恰好都没碰到，由 Codex 的请求暴露。
- **全零槽位重复。**未命中分流最初只有一个全零槽位。9–32 token 的批次里，同一 token 的多个 CPU 未命中指向同一个槽位，CUDA MMQ 的重排每个专家每个 token 只记一行，漏掉的行号未初始化，量化内核越界。改为每个 token 的第 k 个专家用第 k 个全零槽位。
- **PCIe 降速。**有一次开机后 GPU1 的链路只训练到 Gen4，主机到 GPU1 只有 14.4 GB/s，未命中上传慢了一倍，解码从约 25 掉到 17 tok/s（图 4）；重启后恢复。改 BIOS 后第一次开机又出现一次，GPU1 只到 Gen3，主机到 GPU1 只有 1.78 GB/s，同样重启恢复。测速脚本现在会先检查链路。
- **测试 server 退出时卡住。**测试 server 收到退出信号时正好接到外部请求，之后 GPU 和 CPU 都是 0%，只能强制结束。生产 server 重启时也可能碰到。
- **Codex 的 MCP 工具被丢弃。**Codex 每个请求带的 9 个 `namespace` 类型工具，server 不支持，直接跳过，模型看不到。这个问题还没有修。

6.4 重启后的长对话首次预填充

server 重启后 prompt 缓存是空的，Codex 的下一个请求要把整段对话从头算。2026-10-25 的日志里，一段约 10.4 万 token 的多轮对话用了 85.2 s（1,219 tok/s），而单条消息的 12.8 万 token 提示词只要 51.8 s（2,464 tok/s，§5.3）。差别来自检查点：server 在对话中间每隔至

少 8,192 个 token（`--checkpoint-min-step` 的默认值）、在用户消息开头处拆一次调用并建检查点，这段对话因此被拆成至少 16 次调用。每次调用都按自己的末尾跑解码器层，要把第 22–39 层的专家再读一遍，估计多花约 30 s；§5.5 的合并只管最后 2,700 个 token。

可以从两头改。一是调大 `--checkpoint-min-step`（例如 32768），拆的次数少很多，估计能降到 55 s 左右；代价是对话中间能恢复的位置变少，改写历史（例如压缩上下文）时可能要多算一段。二是重启前用 `--slot-save-path` 把槽位状态存盘、重启后读回，第一个请求就不用重算；fork 的基础提交已经支持把检查点一起存进槽位文件，但我们还没有实测。这两项都还没做。

7 把内存提到 5200 MT/s

4 × 48 GB 双 rank、每通道两条时，AMD 默认只跑 3600 MT/s。内存条标称 5600，SPD 里的 XMP 和 EXPO 配置都是 DDR5-6000、1.40 V。我们在 BIOS 里设 EXPO I，再把频率降到 DDR5-5200，并关掉 Memory Context Restore。stressapptest 用 150 GB 压 1 小时通过，没有硬件错误，内存条最高 62 °C；同一编译重跑的对拍和改之前一致，差别和这个编译两次运行之间一样。

表 11 | 内存从 3600 提到 5200 MT/s 前后（2026-10-25）。

测试	3600 MT/s	5200 MT/s
内存纯读	44 GB/s	54 GB/s
两卡同时从主机读	43.4 GB/s	50.6 GB/s
单卡从主机读	28.9 GB/s	28.9 GB/s
9.6 万上下文多轮会话解码	29.0–31.1 tok/s	30.7–33.0 tok/s
多轮智能体首轮 / 之后每轮	24.0 / 2.9–3.5 s	23.1 / 2.7–3.2 s
新提示词 604 / 2,324 / 4,277 token	2.59 / 3.69 / 4.34 s	2.27 / 3.35 / 4.01 s

各项快了 6–12%，少于我们预计的 15–20%。解码时上传到 GPU1 受 PCIe 限制，每个专家约 0.7 ms，和内存频率无关，只有 CPU 算的那一半变快了。内存带宽也只提高了 23%，理论上是 44%，可能是内存控制器频率被自动设成了内存频率的一半，还没有确认。专家缓存的上传比例（0.5）是在 3600 MT/s 下定的，现在 CPU 快了，可能不再最优。

8 把上下文扩到 19.2 万

智能体会话很容易逼近 12.8 万的上下文。Hermes 在窗口用到约 75% 时压缩上下文：先让模型写一份摘要，再把摘要和最近的消息从头预填充。2026-10-26 的一次压缩用了约 4.7 分钟，其中摘要 8,189 token、259 s，重新预填充 36,711 token、22.7 s。它每轮结束后的后台复盘要重放整段对话，上下文已经长到约 11.8 万 token。Codex 则在 11 万 token 时自动压缩。

显存的限制不在 KV。V4.1 的 KV 是压缩过的，从槽位存档估算每 token 约 5 KB（88,630 token 连同 29 个检查点共 443 MB），25.6 万上下文也只要约 1.2 GB。随上下文变大的是 GPU1 的计算缓冲区，主要是稀疏索引器给压缩位置打分的临时空间，大致和「ubatch × 上下文」

成正比：12.8 万上下文时 server 启动预留 4.5 GiB，跑长提示词时涨到 6.1 GiB，GPU1 峰值 96,686 / 97,887 MiB。

我们用 `ctx-size.sh` 逐个试了几种配置（表 12）。每种配置记下加载后的显存，测试全程每 0.5 s 采样一次取峰值；先跑一段 9.6 万 token 的提示词，贪心生成 32 个 token，用来在配置之间对拍；再在开头放一句暗号，灌满语料直到接近上限，最后问暗号，看能否找回，同时测满上下文时的预填充和解码。

表 12 | 各上下文配置的显存与速度（2026-10-27，内存 5200 MT/s）。解码是灌满上下文后生成 256 个 token，开了 `ignore_eos`，答完暗号后的内容容易重复、命中偏高，只适合互相比较。

上下文、ubatch、专家缓存	GPU1 峰值	9.6 万 token	灌满时预填充	解码	暗号
12.8 万、2048、14 GB（原配置）	96,686 MiB	43.2 s	12.8 万，47.9 s	34.1 tok/s	对
12.8 万、1024、14 GB	93,578 MiB	53.4 s	12.8 万，59.4 s	37.7 tok/s	对
19.2 万、1024、14 GB	94,112 MiB	53.1 s	19.3 万，98.4 s	35.0 tok/s	对
25.6 万、1024、14 GB	94,966 MiB	53.1 s	25.9 万，140.0 s	37.7 tok/s	对
19.2 万、2048、10 GB	93,596 MiB	42.9 s	19.3 万，79.7 s	30.9 tok/s	对
19.2 万、2048、12 GB（采用）	**95,604 MiB**	**42.6 s**	**19.3 万，79.4 s**	**33.6 tok/s**	对
19.2 / 25.6 万、2048、14 GB	加载时 GPU1 显存不够（计算缓冲区要 6.7 / 8.6 GiB）				

有两种腾显存的办法。一是把 ubatch 减半，计算缓冲区约减半，25.6 万上下文的 GPU1 峰值也只有 94,966 MiB；代价是大段预填充慢约 24%（9.6 万 token 从 43.2 s 到 53.4 s），而且智能体每轮只新增 1–3K token，在 ubatch 2048 下多是一个 ubatch，减半后要分成两个，第 22–39 层的专家要从内存多读一遍，这部分没有实测。二是保持 ubatch 2048、缩小专家缓存：12 GB 时 19.2 万上下文的 GPU1 峰值 95,604 MiB，还剩约 2.3 GB，比原配置的余量还大，因为 19.2 万时启动预留的计算缓冲区已经够用，跑长提示词时不再上涨。我们采用第二种。Hermes 的压缩阈值随之从约 9.8 万推迟到约 14.7 万，Codex 的自动压缩从 11 万调到 16.5 万。

对拍：同一段 9.6 万 token 的提示词，只改上下文大小时输出逐 token 相同（ubatch 1024 下 12.8 万、19.2 万、25.6 万三者 KL 为 0），采用的配置对原配置 KL 5e-6；ubatch 1024 对 2048 是 0.0066，和只换 ubatch 时的差别一致（§5.5）。19.3 万 token 的提示词在 19.2 万和 25.6 万两种配置上的 32 个 token 相同，KL 6e-4。三种长度都能从开头找回暗号。

表 13 | 上线前后的实际解码，取自 server 的解码统计（每 100 个 token 一个窗口）。两段时间的负载不同：前一段是 Hermes，后一段是 Hermes 和 Codex。

	12.8 万、14 GB	19.2 万、12 GB
时段（2026-10-27）	11:50–14:56	15:25–16:28
窗口数	547	617
每 token 中位数	31.1 ms（32.2 tok/s）	32.1 ms（31.2 tok/s）
最慢的 10%	32.8 ms	33.7 ms
专家缓存命中率	72.2%	69.8%
每 token 上传的专家	15.0	约 16
每轮预填充（0.5–3K token）	2–4 s	2–4 s

上线后的结果见表 13。缓存槽位从约 780 个减到约 670 个，命中率降了约 2.5 个百分点，每 token 多上传约 1 个专家，解码慢约 3%；每轮的预填充不变。另一个代价在最坏情况：崩溃后没有存档、或压缩后重建上下文时，19.3 万 token 从头预填充要约 80 s，12.8 万时约 48 s。

9 结论、局限与未来方向

在一台双卡工作站上，Abyss 以原生 MXFP4 精度、19.2 万上下文运行 DeepSeek-V4.1-Flash：只追加的多轮会话里单流解码 31–33 tok/s，4.8 万和 9.6 万上下文一样；4.8 万 token 提示词的预填充约 23 s，多轮会话每轮约 3 s。收益主要来自四类工作：顺着模型结构减少计算（CED 感知预填充、稀疏索引器、解码注意力只取 top-k），按热度安排数据所在的层级（专家缓存与准入），让 CPU、DMA 和 GPU 同时工作（未命中分流、大批次分流），以及减少重复读取（末段一遍算完）。每一项都先剖析、后实现，并用分档的数值底线和对官方实现的对拍确认正确性。

局限。 解码器专家的读取最终受内存带宽和 PCIe 限制：每个未命中的专家都要从双通道内存读一遍，上传的那一半还要经过 x8 的 PCIe（每个约 0.7 ms），而且一层接一层串行；预填充的大批次也已接近「每层专家读一遍」的下限。GPU1 的链路两天里两次没有训练到 Gen5，每次开机后都要先检查。显存余量很小：上下文扩到 19.2 万是用 2 GB 专家缓存换来的，解码慢约 3%；再往上要把 ubatch 减半，大段预填充慢约 24%（§8）。GGUF 中的 Engram 表从官方的 FP8 降到了 MXFP4（§2.3），这对质量的影响还没有测过。DSpark 投机解码在 V4.1 上尚不支持，这部分收益还没有拿到。

未来方向。

- 在 5200 MT/s 下重新扫专家缓存的上传比例，并确认内存控制器是否和内存同频。
- 合并 GPU 上的小内核：解码时每 token 约 2,900 个内核、14.6 ms，占四成多，平均每个只有约 5 μs。
- 让上传和本层命中专家的计算并行，并减少每层的同步，预计每 token 省 2–3 ms。
- 减少长对话中途检查点带来的重复读取，或在重启时保存并恢复槽位（§6.4）。
- 补上 V4.1 的 DSpark 投机解码。diffbot 在智能体编程会话中开启后解码约为单流的两倍；但在分层布局下，一次验证多个 token 会选中更多不同的专家，要多读的专家可能抵消一部分收益，需要实测。
- 与方案 A（3.0 bpw 专家、vLLM 双卡张量并行，预计 55–75 tok/s）做一次同机对比，量化速度与精度的取舍。

参考资料

[1] DeepSeek-AI. DeepSeek-V4.1-Flash: Pushing the Limits of KV Cache Compression. 2026. https://huggingface.co/deepseek-ai/DeepSeek-V4.1-Flash

[2] mxxm-t. mx-llama.cpp 与 DeepSeek-V4.1-Flash 的 MXFP4 GGUF. https://huggingface.co/mxxm-t/DeepSeek-V4.1-Flash-GGUF

[3] diffbot. DeepSeek-V4.1-Flash-EXL3-3bpw-2x-RTX-PRO-6000. https://huggingface.co/diffbot/DeepSeek-V4.1-Flash-EXL3-3bpw-2x-RTX-PRO-6000

[4] Strata：三层分工的本地 MoE 推理. https://github.com/Niko1221/Strata

A 补丁清单

Abyss 的全部改动以补丁形式保存在仓库的 `mx-llama.cpp/` 目录，基于 mx-llama.cpp 的提交 `c4d12e2`，按序号依次应用。

补丁	作用	开关
0001	server 的专家命中统计	`ABYSS_EXPERT_STATS`
0002	V4.1 的工具调用标签（DSML，标签名带前导空格）	—
0003	CED 感知预填充：解码器层只算可见 token 的 FFN	`ABYSS_CED_PREFILL=1`
0004	Engram 整批预取	`ABYSS_ENGRAM_PREFETCH=8`
0005	CED 感知预填充：注意力也只算子集	同 0003
0006	V4.1 稀疏注意力索引器	`ABYSS_DSV41_INDEXER=1`
0007	`llama-abyss-dump`：导出计算图张量用于对拍	—
0008	单 token 解码时注意力只取 top-k 行	`ABYSS_DSV41_DECODE_GATHER=1`
0009	专家缓存未命中按热度分给上传和 CPU	`ABYSS_MOE_CPU_MISS=1`
0010	修 CED 行映射未分配；未命中分流的全零槽位重复	—
0011	修候选块输入未分配	—
0012	prompt 缓存按能直接用上的 token 数挑选	—
0013	修调度器估算显存时清掉手动指定的后端	—
0014	预填充大批次分流到 CPU	`ABYSS_MOE_BIG_SPLIT=1`
0015	提示词末段一遍算完；CED 余量跟 `n_rs_seq`	`ABYSS_CKPT_TAIL_MERGE=2700` `ABYSS_CED_ALIGN=1`

B 复现

生产配置的启动命令（需打过全部补丁的编译；还必须设 `GGML_CUDA_Q8_1_CACHE=0` 和 `GGML_CUDA_MMQ_PREC=q8`；内存在 BIOS 里设 EXPO I + DDR5-5200）：

```
GGML_CUDA_Q8_1_CACHE=0 GGML_CUDA_MMQ_PREC=q8 \
ABYSS_CED_PREFILL=1 ABYSS_ENGRAM_PREFETCH=8 ABYSS_DSV41_INDEXER=1 \
ABYSS_DSV41_DECODE_GATHER=1 ABYSS_MOE_CPU_MISS=1 ABYSS_MOE_BIG_SPLIT=1 \
ABYSS_CKPT_TAIL_MERGE=2700 ABYSS_CED_ALIGN=1 \
llama-server -m DeepSeek-V4.1-Flash-MXFP4-00001-of-00012.gguf \
  -ngl 99 -sm layer -ts 12/29 -fa 1 -lm dio -c 196608 -b 65536 -ub 2048 \
  -ot "blk\.(2[2-9]|3[0-9])\.ffn_(gate|up|down)_exps\.=CPU" \
  -t 16 -np 1 --moe-cache-mib 12000 \
  --jinja --chat-template-file deepseek-v4.1.jinja
```

评估脚本在仓库的 `tools/eval/`，复制到机器上运行，运行前要先停 server：

脚本	用途
`kl.sh`	存基准 logits，比较 KLD
`bench.sh`	解码与预填充测速
`prefill-warm.sh`	server 热缓存预填充
`profile-prefill.sh`、`profile-decode.sh`	nsys 剖析预填充、解码
`dump-indexer.sh`、`indexer_oracle.py`	稀疏索引器的单层对拍
`decode-gather.sh`、`decode_attn_oracle.py`	解码注意力的 float64 对拍
`engram-cold.sh`、`engram-share.sh`	Engram 冷读开销与占比
`m2-cpu-miss.sh`	未命中分流的上传比例扫描
`agent-turns.sh`	多轮智能体会话
`decode_modes.sh`	只追加的长会话里测解码，`CAPTURE=1` 剖析
`prefill-sizes.sh`	几种长度新提示词的预填充
`ctx-size.sh`	各上下文配置的显存峰值、长提示词预填充和找回暗号

C 术语表

按主题分组；同一个词在不同语境下含义不同的（如「解码器层」和「解码」、server 的槽位和专家缓存的槽位），在条目里分别说明。

模型结构

MoE（混合专家） 每层有许多个前馈网络（专家），每个 token 只由路由器挑出其中几个来算。V4.1-Flash 每层 384 个路由专家，每个 token 选 6 个，另有 1 个共享专家每个 token 都算。

路由器（gate） 每层给 384 个专家打分并选出 top-6 的小矩阵；它选中的专家号决定了这一步要读哪些专家权重。

CED（编码器-解码器结构） V4.1 把 40 层分成前 20 层因果编码器（第 0–19 层）和后 20 层解码器（第 20–39 层）。第 20 层用编码器的输出生成所有解码器层共享的全局 KV；解码器层自己的隐状态只能通过 128 个 token 的滑动窗口被其他 token 看到。所以提示词里较早的 token 不必算完解码器层，这是 CED 感知预填充的依据。

编码器层、解码器层 分别指第 0–19 层和第 20–39 层，是模型结构上的划分；和下面推理过程里的「解码」（逐个生成 token）不是一回事。

滑动窗口注意力（SWA） 每个 token 只看自己和前面 127 个位置的 KV（共 128 个）。

压缩注意力、压缩比 把每 2 个或每 1 个 token 的 KV 压成一行，长程注意力只看压缩后的行。第 0–1 层只有滑动窗口，第 2–19 层压缩比为 2，第 20–39 层为 1。压缩 KV 只在第 2、8、14、20 层（KV 源层）写入，其后的层复用。

全局 KV 第 20 层的压缩器生成、被全部解码器层共享的压缩 KV。

稀疏索引器（lightning indexer） 用 32 个头、128 维、FP4 的查询和键给所有压缩位置打分，为每个查询挑出 top-512 个位置；注意力只看这些位置和滑动窗口，共约 640 行。第 2、8、14、20、24、28、32、36 层是索引源层，其余层沿用最近索引源的结果。

候选块 第 20 层按每 8 个压缩位置一块挑出 2,048 块，第 24–36 层只在这些块里重新选 top-512。

超连接（hc） V4 系列对残差连接的扩展：隐状态保留 4 路，每层注意力和前馈网络的前后按学到的系数把它们混合、写回。解码时它带来不少小内核。

Engram V4.1 的查表模块：第 1、14 层按最近 2–4 个 token 的 n-gram 哈希，从两张各约 3.84 亿行的大表里取行。表很大（官方 FP8 约 189 GiB），但每个 token 只读几十行，所以可以放在 NVMe 上。

DSpark V4.1 自带的约 14B 草稿模型，用于投机解码；mx-llama.cpp 对 V4.1 还不支持。

数值格式与量化

MXFP4 4 bit 浮点（E2M1），每 32 个元素共享一个 8 bit 的 2 的幂缩放（E8M0），平均 4.25 bit/权重。V4.1 路由专家的原生格式。

FP8、BF16、F16、F32 8、16、16、32 位浮点。官方 checkpoint 的稠密权重和 Engram 表是 FP8；KV cache 用 F16。

Q8_0 llama.cpp 的 8 bit 整数格式，每 32 个元素一个 F16 缩放，平均 8.5 bit。GGUF 里的稠密权重是这种格式。

W4A8、W4A4 矩阵乘的精度：权重 4 bit，激活量化到 8 bit 或 4 bit。官方参考实现是 W4A8；fork 在 Blackwell 上的预填充默认是 W4A4，我们用 `GGML_CUDA_MMQ_PREC=q8` 改回 8 bit。

bpw 每个权重平均占的位数。方案 A 把专家从约 4.25 bpw 压到 3.0 bpw。

EXL3 ExLlamaV3 的量化格式，方案 A 的公开配方用它。

GGUF llama.cpp 的模型文件格式；本报告用的是 mxxm-t 转换的 MXFP4 GGUF，共 12 个分片、383 GiB。

推理过程

预填充（prefill） 一次处理整段提示词，写入 KV 并算出第一个 token 的分布。很多 token 一起算，主要受算力和读权重的总量限制。

解码（decode） 每次生成一个 token。每一步都要把用到的权重读一遍，主要受带宽限制。

tok/s 每秒 token 数：预填充指每秒处理的提示词 token，解码指每秒生成的 token。

KV cache 已处理位置的键和值，后面的 token 做注意力时读取。V4.1 的 KV 很小：每个位置只有 1 个 512 维的头，又经过压缩。

llama_decode 调用、ubatch server 把要处理的 token 组成一次 `llama_decode` 调用（上限由 `-b` 决定，本报告用 65536）；一次调用再切成最多 2,048 个 token（`-ub`）的 ubatch，每个 ubatch 把计算图从头到尾跑一遍。

检查点（checkpoint） DeepSeek V4 的缓存不能回退到中间位置。server 在一些位置保存那一刻的完整状态（滑动窗口和压缩器状态），之后的请求如果在这之后才和缓存分叉，就从检查点恢复，不必从头算。

prompt 缓存 server 把处理过的提示词状态（连同检查点）留在内存里，下一个请求前缀相同时直接复用。

server 的槽位（slot） server 同时服务的会话数（`-np`），本报告用 1 个；和专家缓存的槽位无关。

回退环（n_rs_seq） 为投机解码准备的少量回退能力，可以撤销最近几个 token；没开投机解码时为 0，缓存只能退回检查点。

投机解码 用小模型先猜几个 token，再让大模型一次验证，猜对的部分直接接受。

temperature 0（贪心） 每步都取概率最大的 token，同样的输入一定得到同样的输出，适合对拍。

Abyss 调度器

方案 A、方案 B 方案 A 把专家量化到 3.0 bpw，用 vLLM 双卡张量并行（TP2）；方案 B 保留原生 MXFP4，用 mx-llama.cpp 按层切分，是本报告的主线。

层切分 `-sm layer -ts 12/29`：GPU0 放第 0–11 层整层，GPU1 放第 12–39 层的稠密部分和第 12–21 层的专家，第 22–39 层的专家放主机内存。

锁页内存（CUDA_Host） 不会被操作系统换出、GPU 可以直接用 DMA 读取的主机内存；第 22–39 层的专家（121 GiB）放在这里。

专家缓存、bank、槽位 GPU1 上划出一块显存（bank），分成槽位，每个放一个专家：12.8 万上下文时 14 GB、约 780 个，19.2 万时 12 GB、约 670 个；每层有一张从专家号到槽位号的映射表。

命中、未命中、命中率 token 选中的专家已在缓存里叫命中，否则叫未命中；命中率按「token × 专家」计。实际会话里约 65–76%。

LRU 最近最少使用：缓存满了先换出最久没用过的专家。

准入、热度 未命中的专家不是都放进缓存：按衰减热度（每层每步乘 0.99）挑出一定比例（默认 0.5）上传进缓存，其余由 CPU 算。

未命中分流（0009） 解码时把未命中的专家分成两路同时处理：一部分上传到 GPU1 的缓存里算，其余由 CPU 直接用主机内存里的权重算，每个专家只从内存读一遍。

大批次分流（0014） 预填充时超过 32 个 token 的批次，把分到 token 少的专家交给 CPU，其余照常上传到 GPU0。

CED 感知预填充（0003、0005） 解码器层只对后面的 token 还能通过滑动窗口看到的那些 token 计算前馈网络和注意力，KV 照常全部写入。

末段一遍算完（0015） 让提示词最后一段不再被 server 拆成几次调用，并让一次调用的最后一个 ubatch 是满的，解码器层的专家尽量只读一遍。

计算图、split ggml 把一次前向计算表示成计算图，再按算子所在的设备切成几段（split），每段在一个后端（CPU、GPU0 或 GPU1）上执行，段与段之间拷贝数据、同步。

MMQ、MMVQ CUDA 上的量化矩阵乘内核：MMQ 用于超过 8 个 token 的批次（预填充），MMVQ 用于 1–8 个 token（解码）。

CUDA graph 把一串内核录成一次提交，减少逐个启动的开销。

flash attention 不显式存出完整注意力矩阵、分块计算注意力的内核。

评估方法

对拍 同一段输入下，把改动后的输出和改动前或参照实现逐项比较。

KLD（KL 散度） 两个配置在每个位置上输出的概率分布之差，再取平均；0 表示完全相同。本报告用 llama.cpp 的 `llama-perplexity` 计算。

数值底线 不改变语义的改动（换内核、换 ubatch 大小、换计算设备）也会带来的 KLD。只经过解码器层时约 0.0005，经过编码器层时 0.005–0.01（§3.1）。

top-1 一致率 两个配置下概率最大的 token 相同的位置所占的比例。

top-20 KL 只用 server 返回的前 20 个候选的概率估算的 KL，用来在单 token 的解码路径上对拍。

PPL（困惑度） 模型对一段文本的平均「意外程度」，越低越好。

参照实现（oracle） 我们照官方 `inference/model.py` 写的 PyTorch 实现，用同样的输入逐层重算，检查 fork 的每一步。

nsys NVIDIA Nsight Systems，记录 GPU 内核、拷贝和 CUDA 调用的时间线，用来剖析每个 token 的时间花在哪。

stressapptest Google 的内存压力测试工具，反复读写大块内存并校验，用来确认内存提频后没有错误。

硬件与系统

PCIe 5.0 x8、Gen3/4/5 显卡和主机之间的链路：第几代决定每条通道的速率，x8 是 8 条通道。Gen5 x8 实测约 28.9 GB/s；开机时链路训练失败会降到 Gen4 或 Gen3。

P2P 两张显卡之间直接拷贝，本机经过 CPU 转发，单向约 27.7 GB/s。

MT/s、双通道 内存每秒传输次数和通道数，两者决定理论带宽：双通道 3600 MT/s 约 57.6 GB/s，5200 MT/s 约 83.2 GB/s。

2DPC、双 rank 每个内存通道插两条内存；每条内存有两组可以分别寻址的芯片。两者都会让内存控制器难以跑高频率。

EXPO、XMP 存在内存条 SPD 芯片里的超频配置（频率、时序、电压），BIOS 可以一键载入；EXPO 是 AMD 的，XMP 是 Intel 的。

UCLK 内存控制器的时钟。和内存时钟 1:1 同频时延迟最低、带宽最好；1:2 时控制器只跑内存时钟的一半，延迟更高，实际带宽也会打折扣。

页缓存、mmap、MADV_WILLNEED Linux 把读过的文件内容留在内存里（页缓存）；mmap 把文件映射到内存地址，访问时按需读入；`MADV_WILLNEED` 提前告诉内核哪些页马上要用，让它预读。

Max-Q RTX PRO 6000 的 300 W 版本，功耗上限低于 600 W 的工作站版。

Codex、MCP Codex 是 OpenAI 的编程智能体命令行工具，本报告用它作为实际负载的客户端；MCP（Model Context Protocol）是给智能体接入外部工具的协议。